Wykład 2

Struktury systemów komputerowych istotne z punktu widzenia systemu operacyjnego

Uproszczony schemat architektury komputera

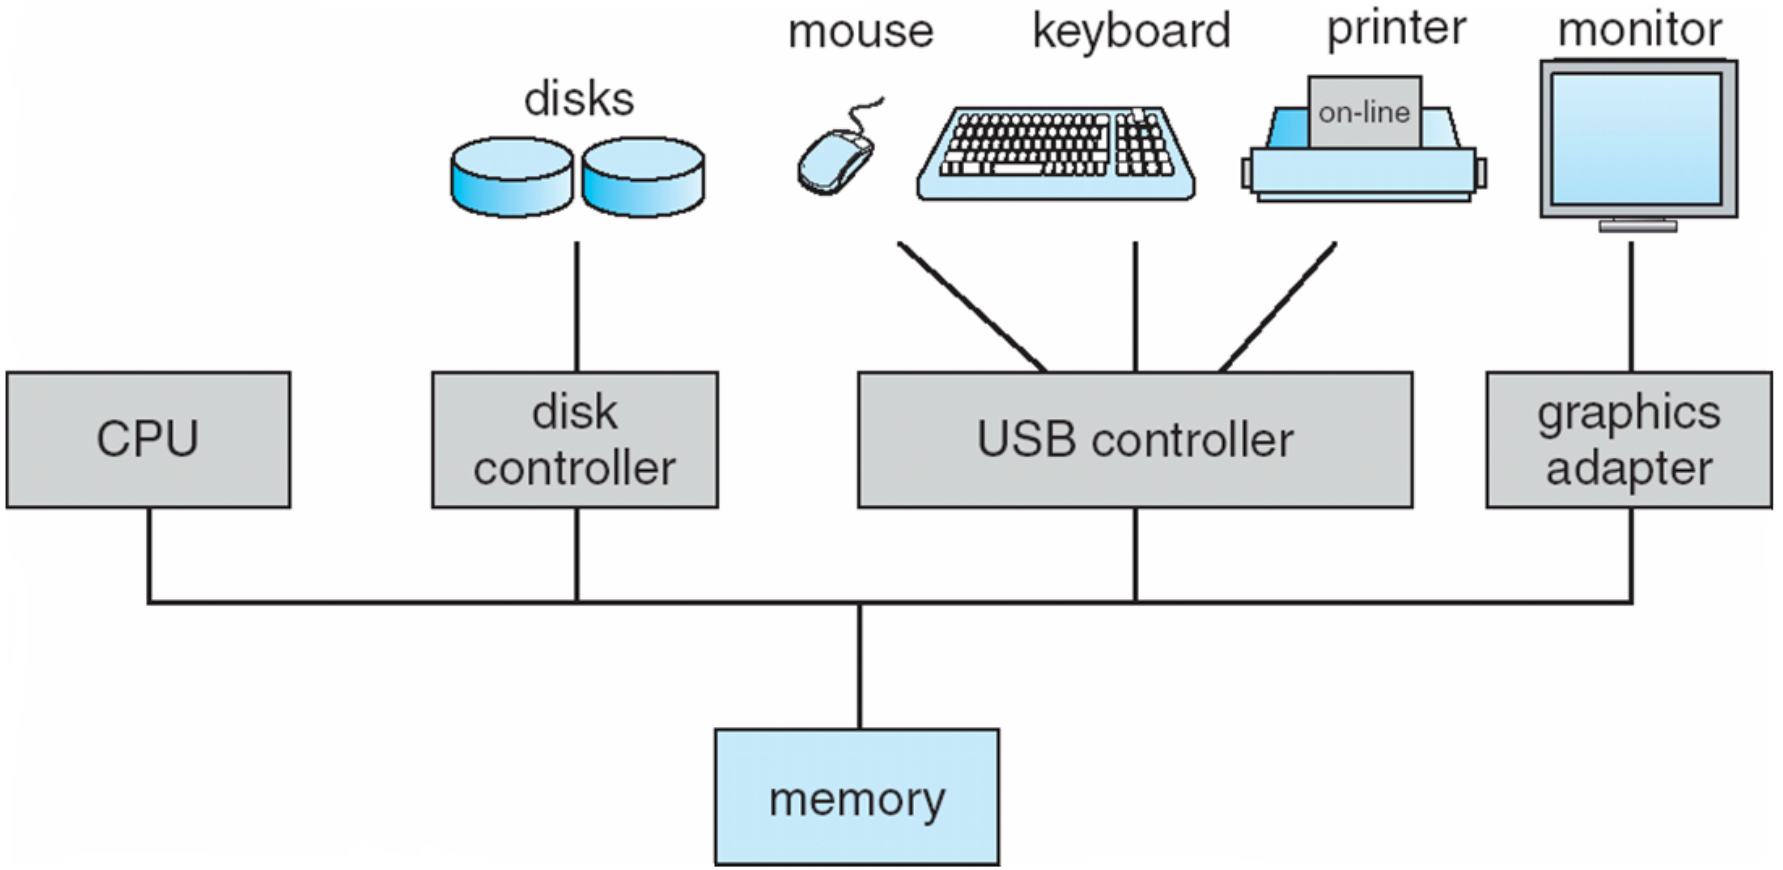

Procesor (lub kilka procesorów) i kontrolery urządzeń we-wy poprzez wspólną **magistralę** podłączone są do współdzielonej pamięci.

Praca systemu komputerowego

Procesor i urządzenia wejścia-wyjścia mogą pracować współbieżnie

Każdy kontroler we-wy obsługuje jeden typ urządzeń

Każdy kontroler-posiada lokalny bufor

Procesor przesyła dane do/z pamięci oraz do/z lokalnych buforów

Wejście-wyjście przeprowadzane jest pomiędzy lokalnym buforem kontrolera a urządzeniem.

Kontroler informuje o zakończeniu operacji zgłaszając **przerwanie.**

SYSTEM OPERACYJNY OPIERA SIĘ NA PRZERWANIACH !!!

Przerwania

- Przerwania programowe (ang. trap)
  - Wywołanie systemu operacyjnego (np. specjalny rozkaz **syscall** w procesorach MIPS)
  - Rozkaz pułapki (brk w x86)
- Sprzętowe zewnętrzne (asynchroniczne względem programu)
  - Kontroler we-wy informuje procesor o zajściu zdarzenia, na przykład
    - Zakończenie transmisji danych.
    - Nadejście pakietu z sieci.
    - Przerwanie zegara.
    - Błąd parzystości pamięci.
- Sprzętowe wewnętrzne, głównie niepowodzenia (ang. fault)
  - Dzielenie przez zero
  - Przepełnienie stosu
  - Brak strony w pamięci (w przypadku implementacji stronicowania)
  - Naruszenie mechanizmów ochrony.

Obsługa przerwania

Wykonywana przez system operacyjny

- Zapamiętanie stanu procesora (rejestrów i licznika rozkazów)
- Określenie rodzaju przerwania
  - przepytywanie (ang. Polling)
  - wektor przerwań (tablica adresów indeksowana numerem przerwania)
- Przejście do właściwej procedury obsługi
- Odtworzenie stanu procesora i powrót z przerwania

Uwaga: Odtworzenie stanu procesora może dotyczyć innego procesu niż zapamiętanie. (**przełączenie kontekstu** – ang. context switch). Przykład:

- Wykonuje się proces A
- Przerwanie zegara=>zapamiętanie stanu procesu A
- System operacyjny stwierdza że A zużył cały przydzielony kwant czasu procesora. System postanawia przekazać sterowanie procesowi B.
- Odtworzenie stanu procesu B(przełączenie kontekstu) => powrót z przerwania
- Wykonuje się proces B

Krótko o procesach

Najprościej możemy określić proces jako ***"Wykonujący się program"***

Ta definicja ma pewne niuanse. Rozpatrzmy przypadek procesu powstałego w wyniku uruchomienia programu użytkownika.

Proces może wywoływać kod tego programu.

Mówimy, że proces ***"proces wykonuje się w trybie użytkownika".***

Może także wywoływać funkcję bibliotek współdzielonych (.so w Linuksie, biblioteki dynamiczne .dll w Windows), które formalnie nie są częścią programu.

Po pewnym czasie proces (tzn. kod programu lub biblioteki) decyduje się wykonać funkcję systemową, np. otworzyć plik

Mówimy wtedy, że ***"proces wykonuje się w trybie jądra".***

W tej sytuacji proces wykonuje kod systemu operacyjnego, a nie kod programu z którego został wczytany.

Widzimy, że nie ma relacji 1<=>1 pomiędzy procesami i programami, ponieważ proces wykonuje kod dwóch programów: swojego i jądra systemu

Wywołanie systemowe w Uniksie

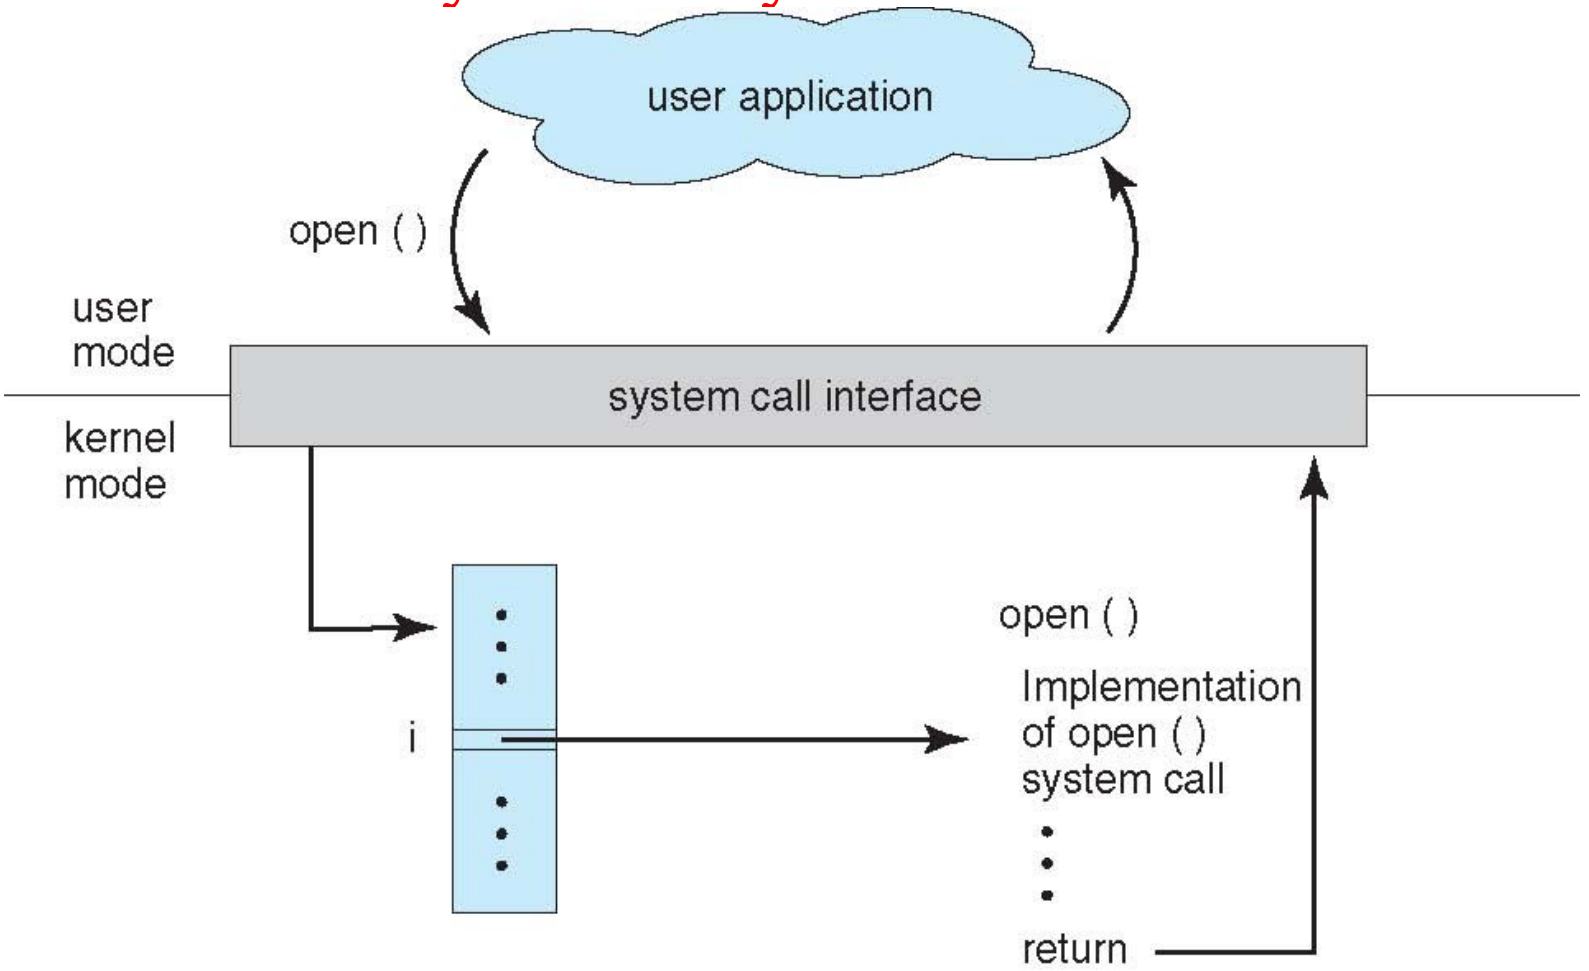

- Aplikacja open wywołuje open jak każdą funkcję w języku C
- Implementacja funkcji open (napisana w asemblerze; ulokowana po stronie użytkownika; ładuje parametry funkcji oraz numer wywołania systemowego (i) do rejestrów procesora, poprzez przerwanie programowe wywołuje jądro)
- Jądro poprzez tablicę rozdzielczą wywołań systemowych odnajduje implementację open

Przykład wywołania systemowego

EXAMPLE OF STANDARD API

As an example of a standard API, consider the `read()` function that is available in UNIX and Linux systems. The API for this function is obtained from the `man` page by invoking the command

```
man read
```

on the command line. A description of this API appears below:

```
#include <unistd.h>

ssize_t     read(int fd, void *buf, size_t count)
```

return value — function name — parameters

A program that uses the `read()` function must include the `unistd.h` header file, as this file defines the `ssize_t` and `size_t` data types (among other things). The parameters passed to `read()` are as follows:

- `int fd`—the file descriptor to be read
- `void *buf`—a buffer where the data will be read into
- `size_t count`—the maximum number of bytes to be read into the buffer

On a successful read, the number of bytes read is returned. A return value of 0 indicates end of file. If an error occurs, `read()` returns −1.

- Programista aplikacji użytkownika musi wiedzieć co zostanie zrobione (interfejs)
- Nie musi wiedzieć jak to zostanie zrobione (implementacja)

Wywołania systemowe w Windowsach i Uniksie

	Windows	Unix
Process Control	CreateProcess() ExitProcess() WaitForSingleObject()	fork() exit() wait()
File Manipulation	CreateFile() ReadFile() WriteFile() CloseHandle()	open() read() write() close()
Device Manipulation	SetConsoleMode() ReadConsole() WriteConsole()	ioctl() read() write()
Information Maintenance	GetCurrentProcessID() SetTimer() Sleep()	getpid() alarm() sleep()
Communication	CreatePipe() CreateFileMapping() MapViewOfFile()	pipe() shmget() mmap()
Protection	SetFileSecurity() InitlializeSecurityDescriptor() SetSecurityDescriptorGroup()	chmod() umask() chown()

Sterowniki urządzeń we-wy (ang. device drivers)

Fragment kodu jądra usytuowany pomiędzy kontrolerem we-wy a resztą jądra.

- Zapewnia to standaryzacje interfejsu do różnego rodzaju urządzeń.
- Jądro wykorzystuje interfejs (zunifikowany) do komunikacji ze sterownikami urządzeń.

Sterownik komunikuje się z kontrolerem przy pomocy magistrali systemowej.

Kontroler komunikuje się z urządzeniem we-wy.

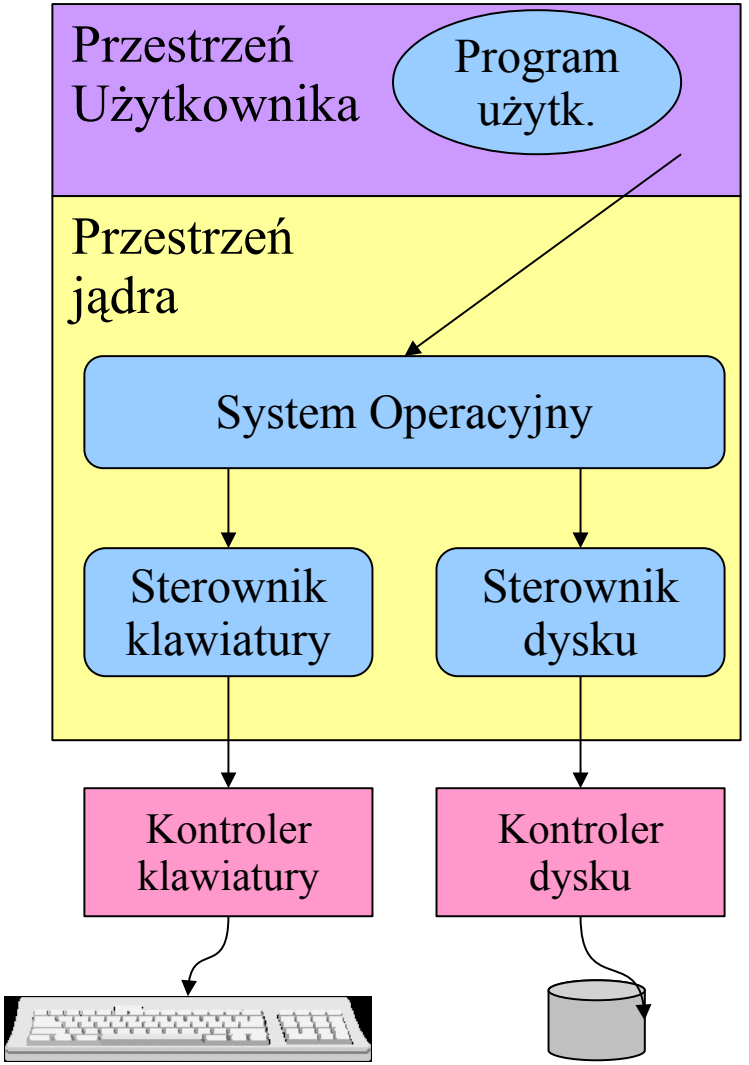

Przykład interfejsu jądro <=> sterowniki: Linux 2.0.x

```
struct file_operations {
 int (*lseek) (struct inode *, struct file *, off_t, int);
 int (*read) (struct inode *, struct file *, char *, int);
 int (*write) (struct inode *, struct file *, const char *, int);
 int (*readdir) (struct inode *, struct file *, void *, filldir_t);
 int (*select) (struct inode *, struct file *, int, select_table *);
 int(*ioctl)(struct inode*,struct file*,unsigned int,unsigned long);
 int(*mmap)(struct inode *, struct file *, struct vm_area_struct *);
 int (*open) (struct inode *, struct file *);
 void (*release) (struct inode *, struct file *);
 int (*fsync) (struct inode *, struct file *);
 int (*fasync) (struct inode *, struct file *, int);
 int (*check_media_change) (kdev_t dev);
 int (*revalidate) (kdev_t dev);
};
```

Struktura file_operations, której każde pole jest adresem funkcji.

Sterownik musi (A) utworzyć egzemplarz struktury (B) wypełnić pola (nie wszystkie są obowiązkowe) adresami funkcji wykonujących odpowiednie czynności (B) zarejestrować się w systemie, podając adres stworzonej struktury.

Synchroniczne wejście-wyjście

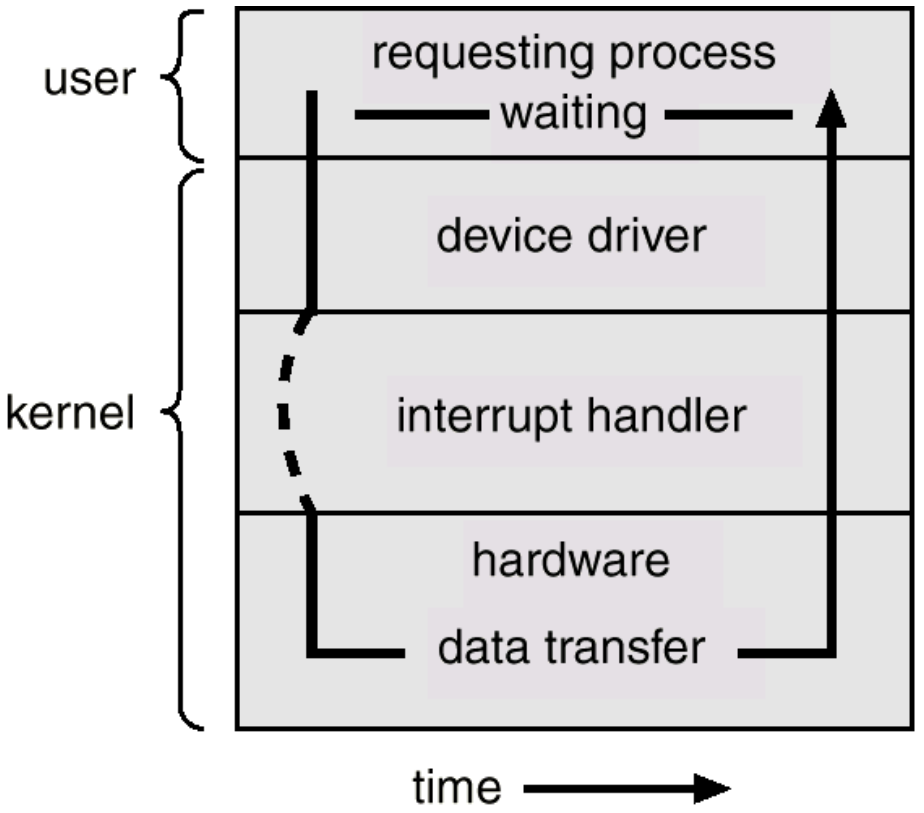

Powrót z systemu operacyjnego po przeprowadzeniu operacji we-wy

Proces żądający operacji we-wy jest wstrzymywany na jej czas trwania

W tym czasie procesor może zostać przydzielony innemu procesowi.

Różnice w prędkości transmisji urządzeń zewnętrznych (Tanenbaum, 2013)

Device	Data rate
Keyboard	10 bytes/sec
Mouse	100 bytes/sec
56K modem	7 KB/sec
Scanner at 300 dpi	1 MB/sec
Digital camcorder	3.5 MB/sec
4x Blu-ray disc	18 MB/sec
802.11n Wireless	37.5 MB/sec
USB 2.0	60 MB/sec
FireWire 800	100 MB/sec
Gigabit Ethernet	125 MB/sec
SATA 3 disk drive	600 MB/sec
USB 3.0	625 MB/sec
SCSI Ultra 5 bus	640 MB/sec
Single-lane PCIe 3.0 bus	985 MB/sec
Thunderbolt 2 bus	2.5 GB/sec
SONET OC-768 network	5 GB/sec

Przestrzeń adresowa urządzeń we-wy

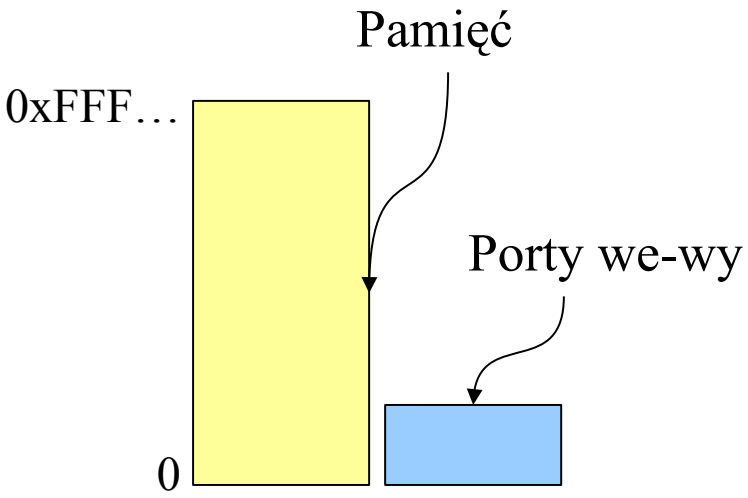

Odrębna przestrzeń adresowa dla portów we-wy.

Specjalne rozkazy we-wy odwołujące się do portów

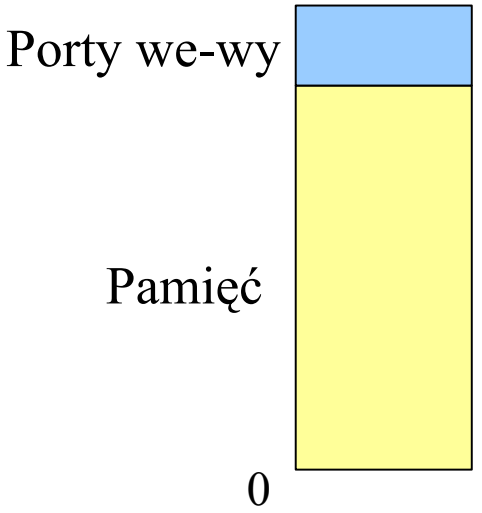

Porty we-wy w tej samej przestrzeni adresów, co pamięć.

Dostęp do portów we-wy za pomocą tych samych rozkazów, co dostęp do pamięci

Metoda 1: Programowane wejście-wyjście (ang. Programmed Intput-Output - PIO)

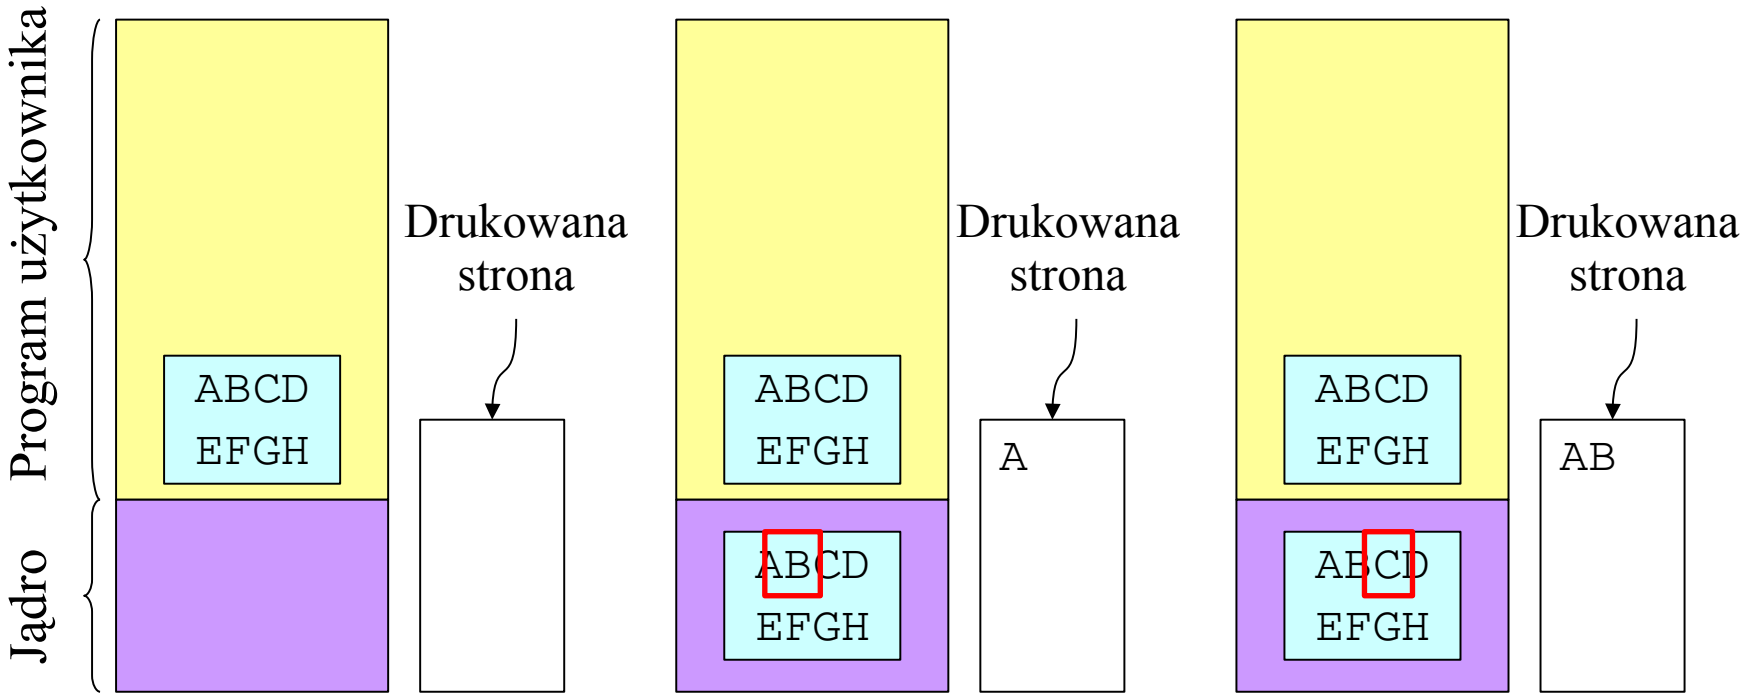

Drukowanie wiersza tekstu na drukarce.

Odrębny bufor we-wy w pamięci jądra.

Programowe wejście-wyjście (ciąg dalszy)

Kod wykonywany przez system operacyjny

```
copy_from_user (buffer, p, count);  // kopiuj dane do bufora jądra
for (j = 0; j < count; j++) {       // przesyłaj odrębnie każdy znak
  while (*printer_status_reg != READY)
    ;                               // czekaj aż drukarka stanie się wolna
  *printer_data_reg = p[j];         // wyślij pojedynczy znak do drukarki
}
return_to_user();                 // powrót do programu użytkownika
```

Dwa rejestry we-wy:

`printer_status_reg`: Aktualny stan drukarki (czy może odebrać następny znak)
`printer_data_reg`: Bajt danych wysyłany do drukarki.

Problem: bezczynne oczekiwanie procesora w pętli while

Drukarka jest ***znacznie*** wolniejsza od procesora

Metoda 2: Wejście-wyjście sterowane przerwaniami (ang. interrupt driven)

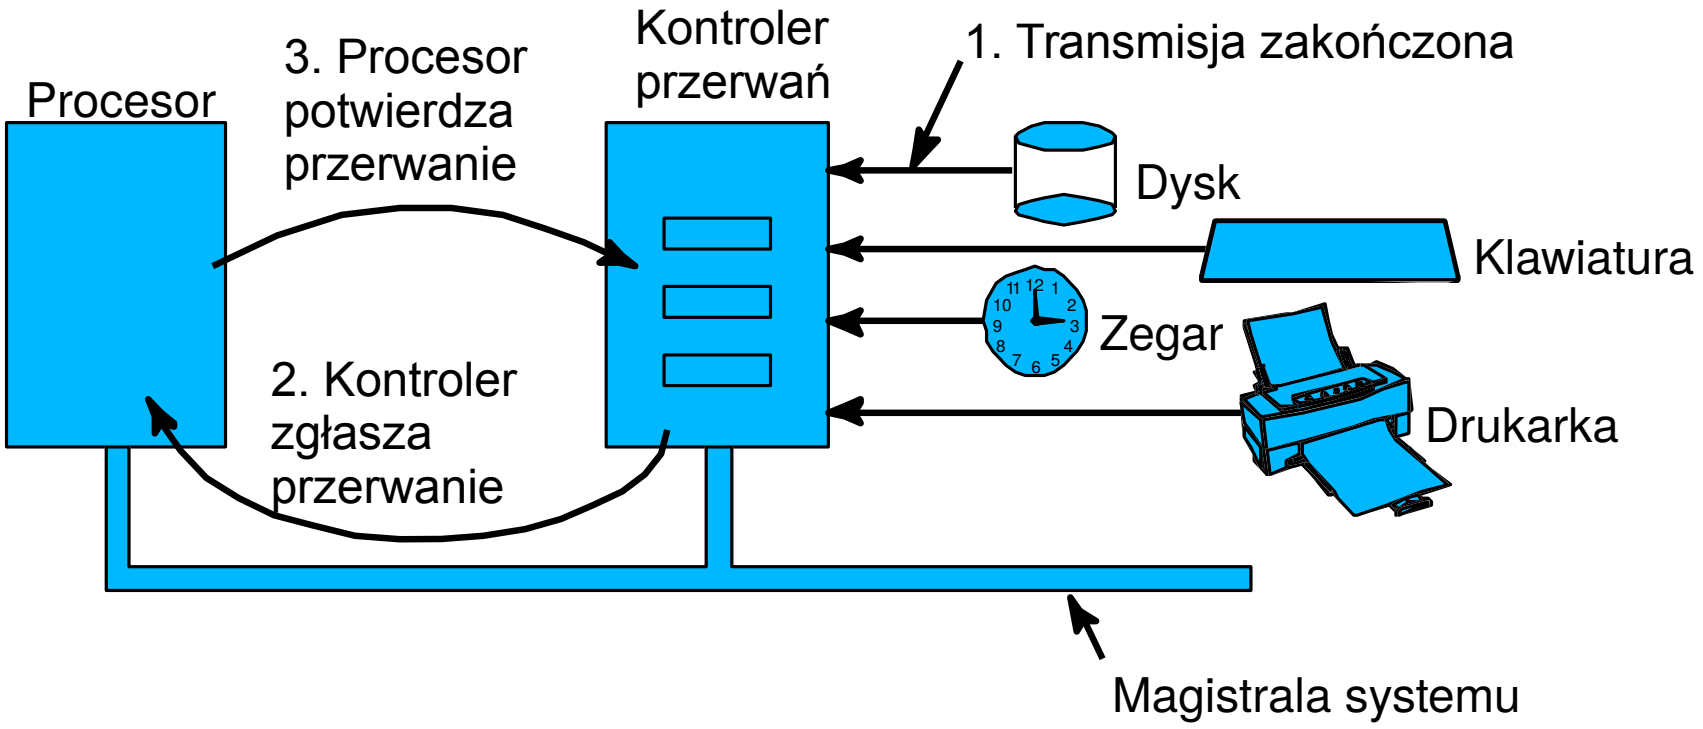

Zakończenie transmisji każdego znaku (niekoniecznie pojedynczego znaku, ale o tym później) potwierdzane jest przerwaniem.

Metoda 2: Wejście-wyjście sterowane przerwaniami (ang. interrupt driven)

Kod wykonywany przez wywołanie systemowe

```
copy_from_user (buffer, p, count);
j = 0;
enable_interrupts();
while (*printer_status_reg != READY)
  ;
*printer_data_reg = p[0];
scheduler();
```

Wstrzymaj (zablokuj) bieżący proces i uruchom inny gotowy do wykonania

```
if (count == 0) {
  unblock_user();
} else {
  *printer_data_reg = p[j];
  count--;
  j++;
}
acknowledge_interrupt();
return_from_interrupt();
```

Odblokuj zablokowany proces (zablokowany proces może powrócić do kodu użytkownika)

Procedura obsługi przerwania

Urządzenie zgłasza przerwanie po odebraniu każdego bajtu.

Wejście-wyjście sterowane przerwaniami

Zaleta: Możliwość wykorzystania procesora w czasie przeprowadzania wejścia-wyjścia

Wada: Większy narzut związany z przesyłaniem jednego bajtu (przejście do procedury, obsługa, potwierdzenie, powrót przerwania)

Gdy szybkość procesora jest znacznie większa od szybkości urządzenia, nie stanowi to problemu. Niech obsługa przerwania zajmuje minimum 2 us.

Przyjmijmy, że wolna drukarka zgłasza przerwania co 1 ms (prędkość transmisji 1000 bajtów/s), w takim przypadku obsługa przerwań obciąża procesor w **0.2%.**

Jeżeli szybki dysk zgłasza przerwania co 4us (prędkość transmisji 250 000 bajtów/s), to obsługa przerwań obciąża procesor w **50%.**

Gdy prędkość transmisji przekracza 500 000 bajtów na sekundę wykorzystanie tej metody (przerwanie po każdym bajcie) nie jest możliwe.

W takiej sytuacji tryb PIO może pozwolić na szybszą transmisję danych.

Możemy próbować łączyć tryb PIO z buforowaniem po stronie kontrolera, i ze zgłaszaniem przerwania po przesłaniu całego sektora.

Pytanie: Czy musimy angażować procesor do przesyłania danych pomiędzy urządzeniem wewnętrznym i pamięcią ?

Metoda 3: Bezpośredni dostęp do pamięci (Direct Memory Access - DMA)

Przesyłanie **bloku** danych pomiędzy urządzeniem a pamięcią odbywa się bez angażowania procesora.

Przesłanie bloku poprzez DMA jest współbieżne z pracą procesora.

Gdy nadejdzie czas przesłania kolejnego bajtu urządzenie DMA przejmuje (na chwilę) od procesora kontrole nad magistralą – ang. **cycle stealing.**

Następuje transmisja bajtu pomiędzy urządzeniem i pamięcią. W tym czasie procesor ma zablokowany dostęp do magistrali. (Nie musi to oznaczać zatrzymania pracy procesora – jeżeli posiada on pamięć podręczną)

Po przesłaniu bajtu urządzenie DMA zwalnia magistralę.

Przerwanie generowane jest po przesłaniu kompletnego bloku danych.

Bardzo mały narzut związany z przesłaniem jednego bajtu.

Metoda wykorzystywana w sytuacji, w której szybkość urządzenia zewnętrznego jest zbliżona do szybkości pamięci.

Organizacja DMA

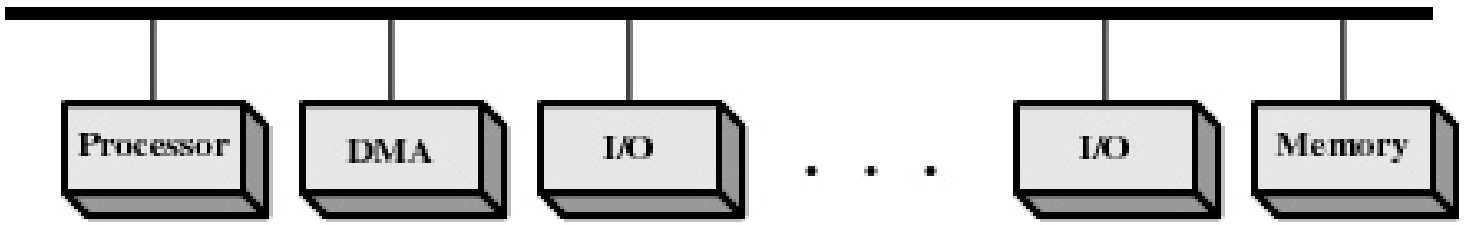

(a) DMA jest kolejnym modułem podłączonym magistrali

Transfer może wymagać dwóch cykli magistrali

Starsze systemy (Z80, IBM PC AT)

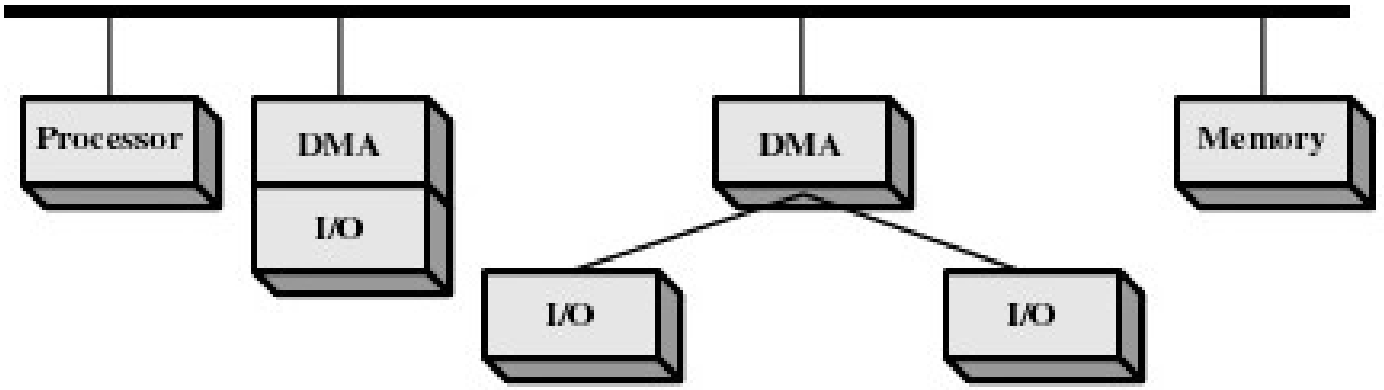

(b) DMA zintegrowane z kontrolerem urządzenia

Nowsze systemy (magistrala PCI).

Operacja z wykorzystaniem DMA

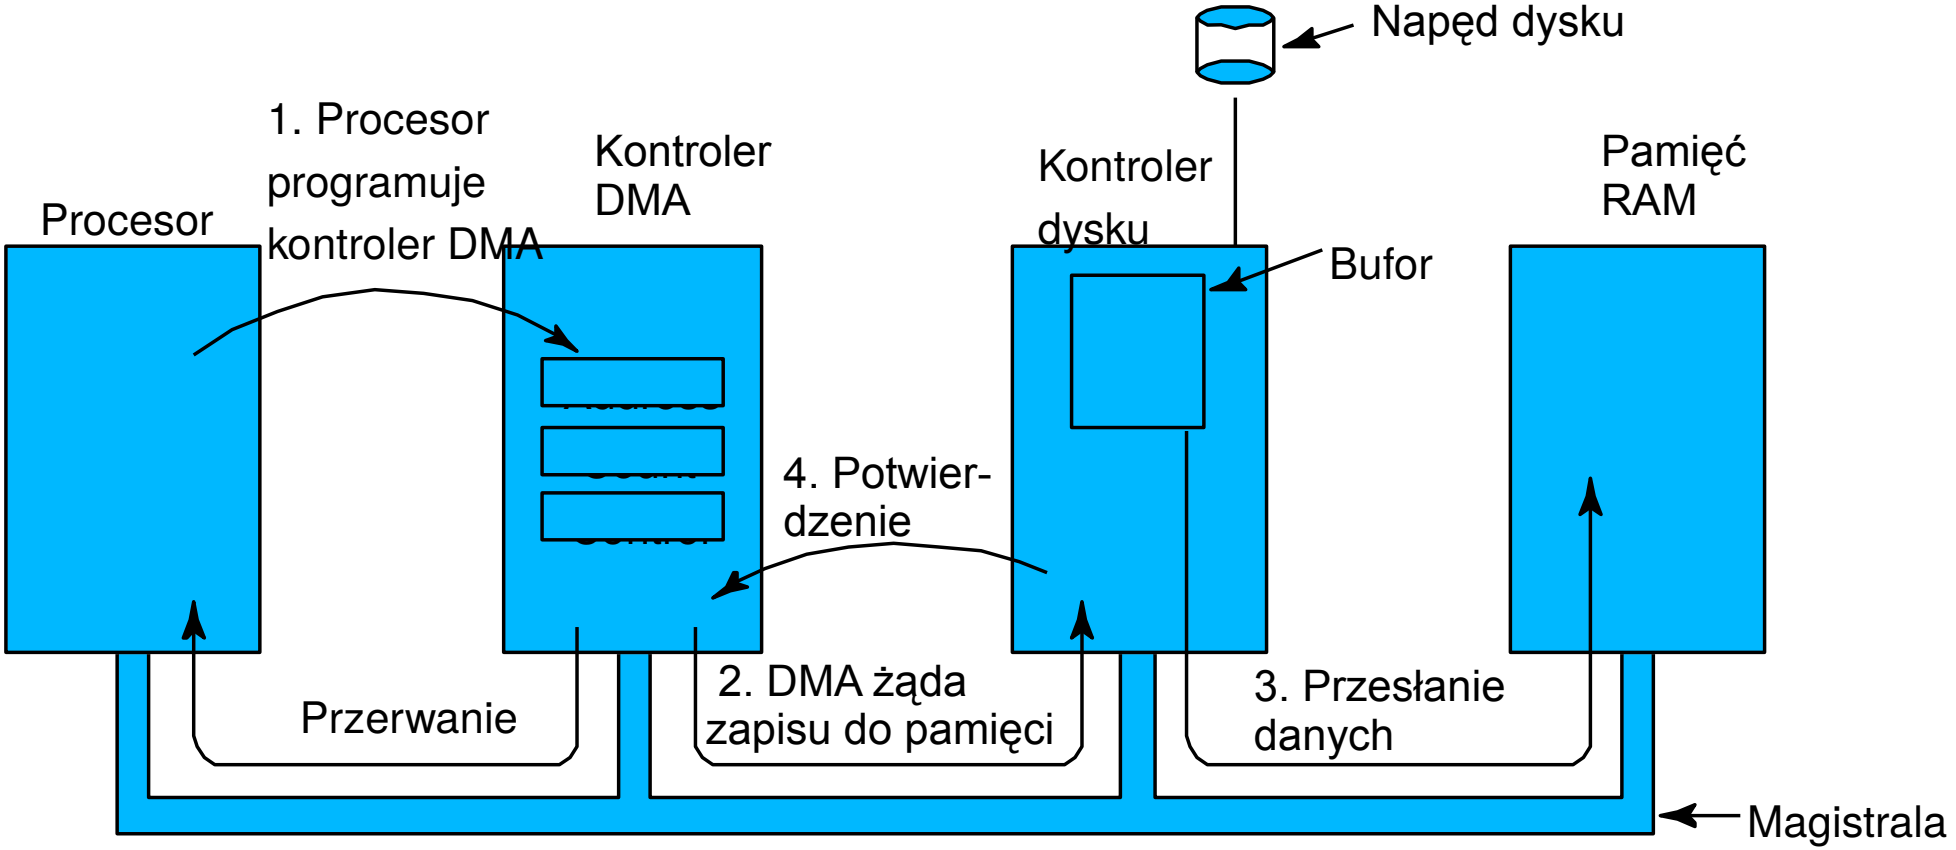

Address – gdzie przesłać dane, Count – ile przesłać, Control – rodzaj operacji (np. odczyt zapis).

Kontoler DMA zajmuje się zliczaniem bajtów, podawaniem adresu i sygnałów sterujących na magistralę (punkty 2,3,4)

Operacja we-wy z wykorzystaniem DMA

Kod wykonywany przez wywołanie systemowe

```
copy_from_user (buffer, p, count);
set_up_DMA_controller();
scheduler(); // wstrzymaj aktualny proces
             // i przekaż procesor innemu
```

Kod wykonywany przez procedurę obsługi przerwania

```
acknowledge_interrupt();
unblock_user(); // odblokuj czekający proces
return_from_interrupt();
```

`set_up_DMA_controller()` - zaprogramuj DMA (numer urządzania, adres bufora w pamięci, liczba bajtów)

DMA zajmuje się zliczaniem bajtów i oczekiwaniem na gotowość urządzenia

Asynchroniczne wejście-wyjście

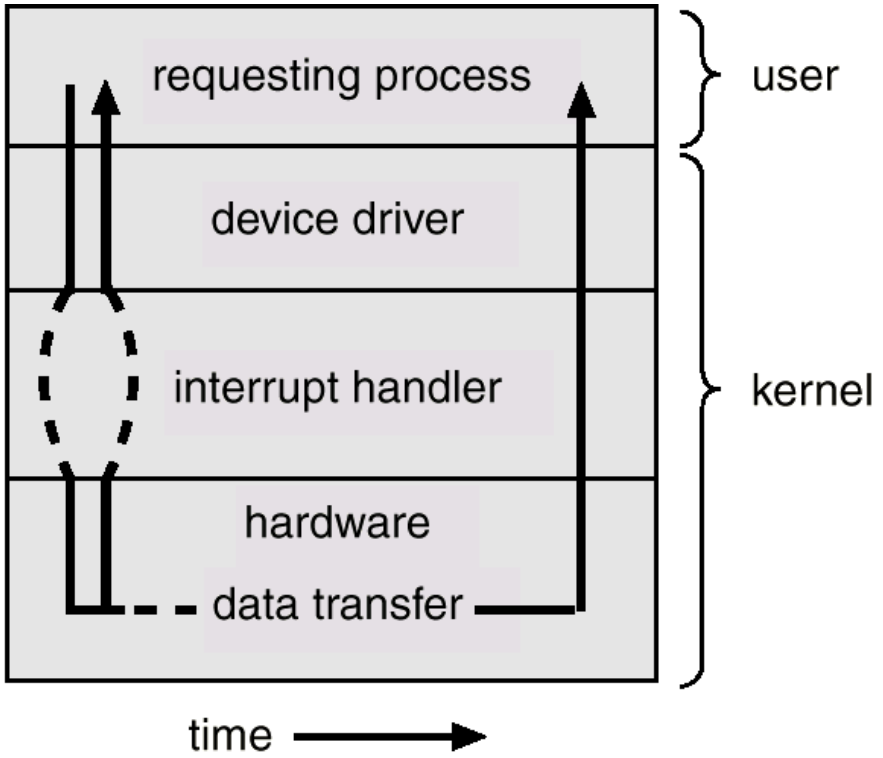

Powrót z systemu operacyjnego po **zainicjalizowaniu** operacji we-wy

Proces co jakiś czas sprawdza czy operacja się zakończyła

W tym rozwiązaniu w czasie trwania operacji we-wy możliwe jest wykorzystanie procesora przez ten sam proces.

Hierarchia pamięci

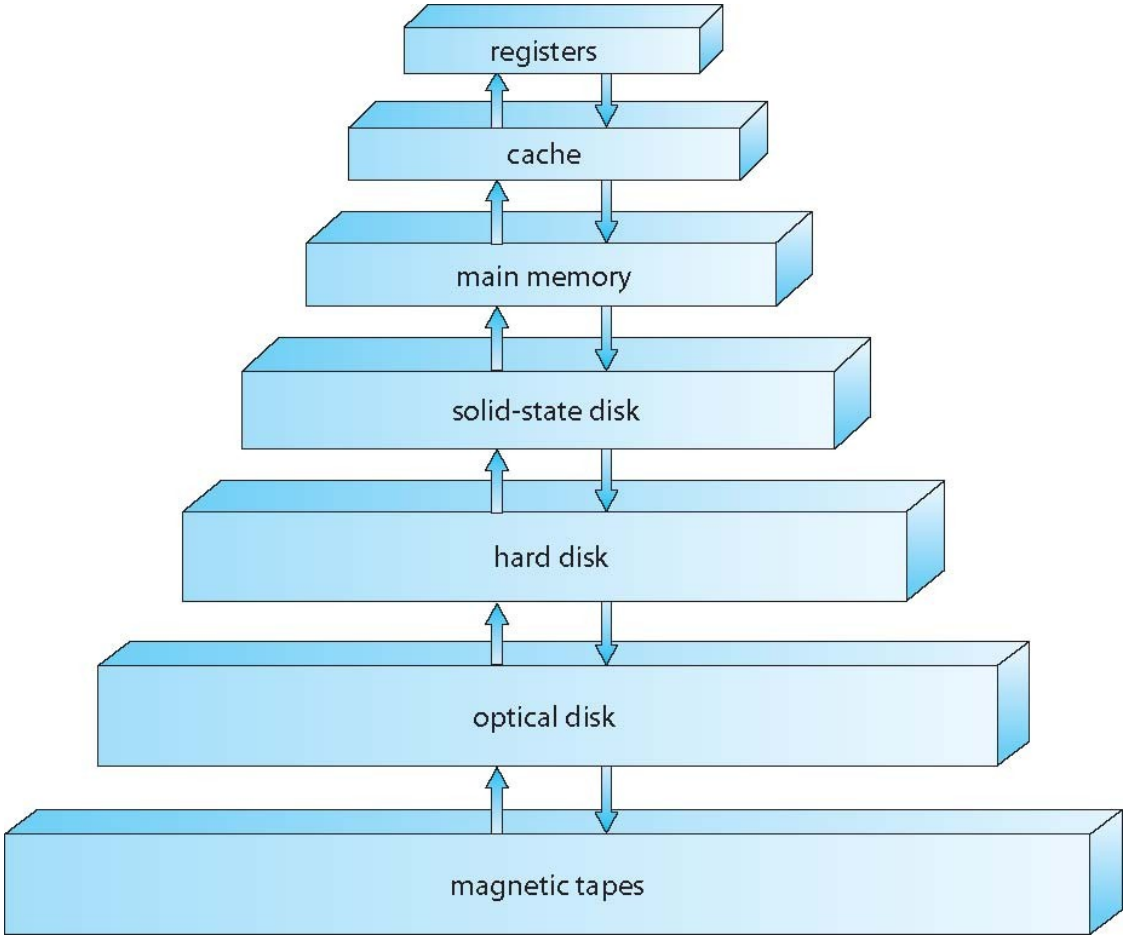

Przemieszczając się w dół hierarchii

- Zwiększamy czas dostępu
- Zmniejszamy koszt jednego bajtu

Różnice pomiędzy poziomami hierarchii

Level	1	2	3	4	5
Name	registers	cache	main memory	solid state disk	magnetic disk
Typical size	< 1 KB	< 16MB	< 64GB	< 1 TB	< 10 TB
Implementation technology	custom memory with multiple ports CMOS	on-chip or off-chip CMOS SRAM	CMOS SRAM	flash memory	magnetic disk
Access time (ns)	0.25 - 0.5	0.5 - 25	80 - 250	25,000 - 50,000	5,000,000
Bandwidth (MB/sec)	20,000 - 100,000	5,000 - 10,000	1,000 - 5,000	500	20 - 150
Managed by	compiler	hardware	operating system	operating system	operating system
Backed by	cache	main memory	disk	disk	disk or tape

- Czas dostępu (access time) – czas od momentu wysłania żądania do urządzenia do momentu otrzymania pierwszego bitu.
- Przepustowość (bandwidth) prędkość z jaką spływają dane.
- Zarządzenie niektórymi poziomami hierarchii może być ukryte przed programistą (jądra albo programów użytkownika)

Wykorzystanie pamięci podręcznych (ang. caching)

Wykorzystanie szybkiej pamięci do przechowywania najczęściej używanych danych.

- Pamięć podręczna procesora.
- Pamięc podręczna dysku.

Wymaga wprowadzenie polityki zarządzania pamięcią podręczną.

Problem spójności pamięci podręcznej: (ang. cache coherency) Informacja przechowywana w pamięci podręcznej niezgodna z informacją przechowywaną w pamięci głównej

- Przykład 1. System dwuprocesorowy. Każdy procesor ma własną pamięć podręczną. Zawartość jednej komórki pamięci przechowywana w obydwu pamięciach podręcznych. Procesor A zapisuje tę komórkę, Procesor B próbuje odczytu .....
- Przykład 2. Pamięć podręczna dysku. Zmodyfikowana zawartość pewnych sektorów dysku jest przechowywana przez pewien czas w pamięci operacyjnej zanim zostanie zapisana fizycznie na dysk. Jeżeli w tym czasie nastąpi załamanie systemu .....

Mechanizmy ochrony (ang. protection)

Potrzeba zapewnienia, że "źle sprawujący się program" nie zakłóci pracy innych programów i samego systemu operacyjnego. Program użytkownika nie może być w stanie wykonać pewnych operacji.

Przykłady "złego zachowania się programu"

Bezpośrednia komunikacja z urządzeniami wejścia-wyjścia => **ochrona we-wy**

Dostęp do pamięci należącej do innych procesów lub do systemu => **ochrona pamięci**

Zablokowanie przerwań, zmiana wektora przerwań => **ochrona systemu przerwań**

Nieskończona pętla => **ochrona procesora**

Program użytkownika nie ma prawa wykonać żadnej z powyższych operacji !!!

Podwójny tryb pracy

Procesor może wykonywać instrukcje w jednym z dwóch trybów

Tryb jądra (instrukcje wykonywane przez system operacyjny)

Tryb użytkownika (instrukcje wykonywane przez program użytkownika)

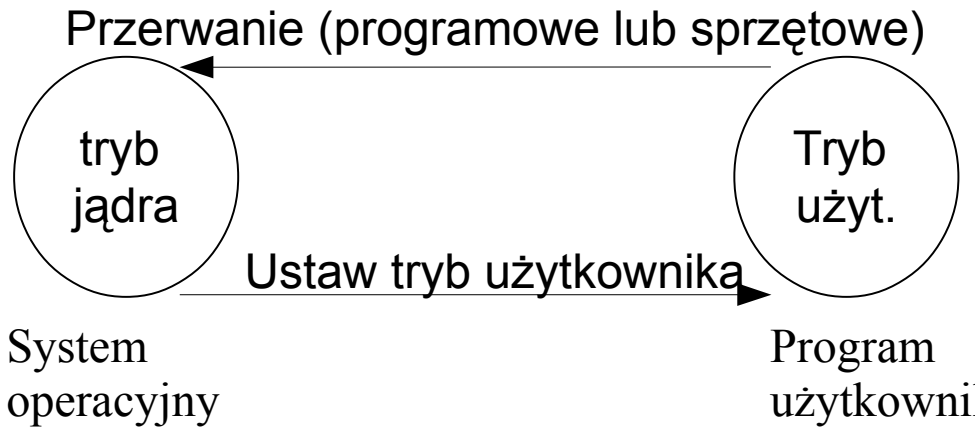

Instrukcje uprzywilejowane – mogą być wywoływane wyłącznie w trybie jądra

Próba ich wykonania w trybie użytkownika powoduje przerwanie i przejście do systemu operacyjnego

Mechanizmy ochrony

Instrukcje uprzywilejowane

- Instrukcje do komunikacji z urządzeniami we-wy
- Blokowanie/odblokowanie przerwań
- Zmiana wektora przerwań
  - Aby zapewnić, że program użytkownika nigdy nie wykona się w trybie jądra

Przerwanie zegara:

- gwarantuje ochronę procesora przed programem użytkownika z nieskończoną pętlą

Przykład realizacji ochrony pamięci: rejestry bazowy i limitu

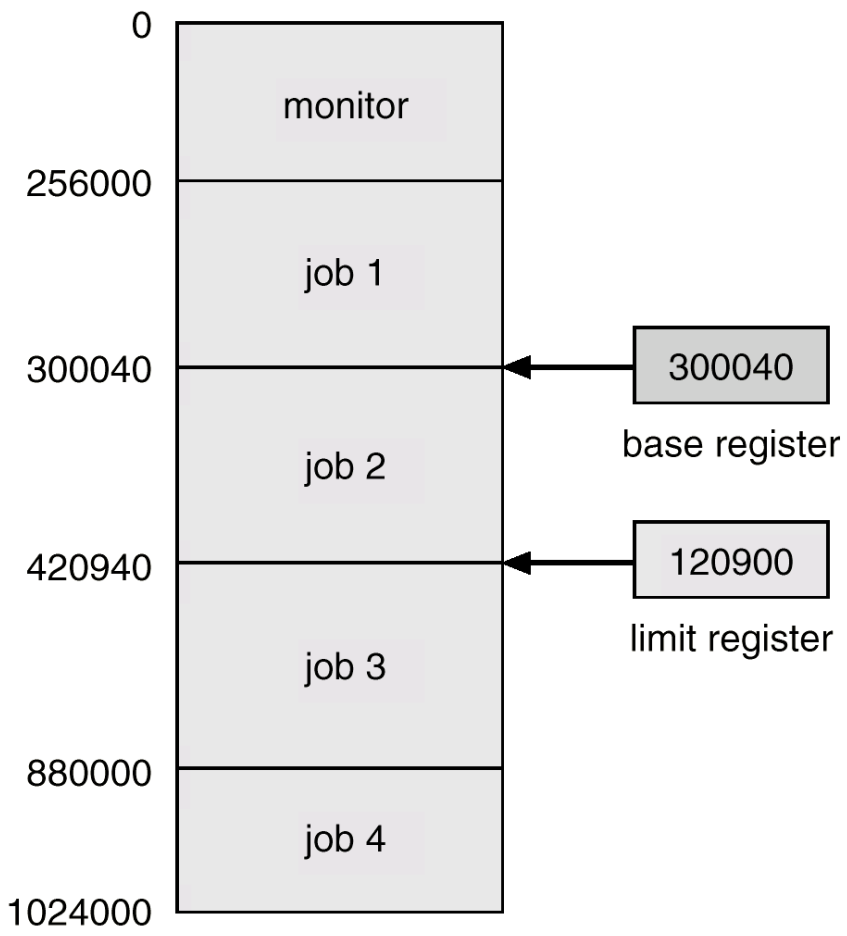

Rejestry te określają zakres dopuszczalnych adresów procesu.

B – rejestr bazowy (ang. base)

L – rejestr limitu

A – adres pamięci, do którego odwołuje się program

Jeżeli $B \leq A < B+L$ => w porządku

W przeciwnym wypadku generuj przerwanie (obsługiwane przez system operacyjny)

Rozkazy zmieniające wartość rejestrów bazowego i limitu są rozkazami uprzywilejowanymi.